



## **ML Advanced**

Kubernetes, контейнерная оркестрация



## Меня хорошо видно **&&** слышно?



Ставим "+", если все хорошо "-", если есть проблемы

#### Тема вебинара

### Kubernetes, контейнерная оркестрация



#### Гайнуллин Дмитрий

Machine Learning Engineer в AIC

- Разработка моделей для распознавания речи
- Прогнозирование ключевых метрик
- Развертывание моделей в продакшене

## Правила вебинара



Активно участвуем



Off-topic обсуждаем в учебной группе



Задаем вопрос в чат или голосом



Вопросы вижу в чате, могу ответить не сразу

#### Условные обозначения



Индивидуально



Время, необходимое на активность



Пишем в чат




Говорим голосом



Документ



Ответьте себе или задайте вопрос



## Цели вебинара

Познакомимся с контейнерной оркестрацией

Познакомимся с Kubernetes

Посмотрим как разворачивать образы в Kubernetes

### Смысл

1

Сможем работать с Kubernetes

2

Сможем запускать свои контейнеры в Kubernetes

## Маршрут вебинара

Мотивация

Контейнерная оркестрация

Знакомство с Kubernetes

Реализации Kubernetes

Компоненты Kubernetes

Модули (Pods)

Контроллер репликации

Развёртывания (Deployment)

Службы (Service)

Model-as-a-Service

Deploy в Kubernetes


Рефлексия

# Мотивация

## Модель как услуга (Model-as-a-Service)



### Развёртывание с помощью контейнеров Docker



# Вопросы?




Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

# Контейнерная оркестрация

## Контейнеры




## Среда выполнения контейнеров

- Docker
- Containerd
- CRI-O
- Kubernetes CRI (<u>Container Runtime Interface</u>)

### Много сервисов

- Приложение это контейнер
- Приложениям нужны ресурсы
- Разным приложениям нужно разное количество ресурсов
- Приложения работают на разных машинах
- Разные машины имеют разную конфигурацию
- Приложения должны знать друг о друге
- Сложно рассчитать потребление ресурсов



## Контейнерная оркестрация

Оркестрация — это координация взаимодействия контейнеров

- Размещение (кого куда поставить)
- Реплицирование / Масштабирование
- Проверка готовности сервиса
- Перезапуск
- Перепланирование
- Управление сервисами
  - Обнаружение (service discovery)
  - Балансировка (load balancing)

### Оркестраторы

- Kubernetes https://kubernetes.io
- Docker Swarm https://docs.docker.com/engine/swarm/
- Apache Mesos <a href="http://mesos.apache.org/">http://mesos.apache.org/</a>
- Nomad <a href="https://www.nomadproject.io/">https://www.nomadproject.io/</a>

# Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

## Знакомство с Kubernetes


### Что такое Kubernetes?

Kubernetes (K8s) - это открытое программное обеспечение автоматизации развёртывания, масштабирования и управления контейнеризированными приложениями

Kubernetes группирует контейнеры, составляющие приложение,

в логические единицы для более простого управления и

обнаружения




### Что может Kubernetes?

- Мониторинг сервисов и распределение нагрузки сбалансировать нагрузку и распределить сетевой трафик
- Оркестрация хранилища автоматически смонтировать систему локальное или облачное хранилище
- **Автоматическое развертывание и откаты** автоматизировать создание новых, удаления существующих и распределения всех их ресурсов в новый

### Что может Kubernetes?

- Автоматическое распределение нагрузки разместить контейнеры на узлах так, чтобы наиболее эффективно использовать ресурсы
- Самоконтроль перезапускает отказавшие, заменяет и завершает работу контейнеров, которые не проходят проверку работоспособности
- Управление конфиденциальной информацией и конфигурацией хранить и управлять конфиденциальной информацией, такой как пароли, OAuth-токены и ключи SSH

## Что делает Kubernetes?



## Как определить, нужен ли Bam Kubernetes?

- 1) Тип системы
- 2) Тип нагрузки
- 3) Доступ к кластеру у DevOps
- 4) Кто владеет кластером
- 5) Готовы ли вы менять процессы под развёртывание в k8s
- 6) Оцените операционный контекст

https://vas3k.club/post/2570/

# Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

# Реализации Kubernetes

### Локальные

- Minikube vs. kind vs. k3s What should I use?
   <a href="https://shipit.dev/posts/minikube-vs-kind-vs-k3s.html">https://shipit.dev/posts/minikube-vs-kind-vs-k3s.html</a>
- minikube <a href="https://minikube.sigs.k8s.io/docs/">https://minikube.sigs.k8s.io/docs/</a>
- kind <a href="https://kind.sigs.k8s.io/">https://kind.sigs.k8s.io/</a>
- k3s <a href="https://k3s.io/">https://k3s.io/</a>
- VMware Tanzu Community Edition <u>https://tanzucommunityedition.io/</u>
- OKD <a href="https://www.okd.io/">https://www.okd.io/</a>

### Промышленные

Red Hat OpenShift

https://www.redhat.com/en/technologies/cloud-computing/openshift

VMware Tanzu <a href="https://tanzu.vmware.com/">https://tanzu.vmware.com/</a>

### Облачные

- Amazon Elastic Kubernetes Service <u>https://aws.amazon.com/eks</u>
- Google Kubernetes Engine <u>https://cloud.google.com/kubernetes-engine</u>
- Azure Kubernetes (AKS)
   https://azure.microsoft.com/ru-ru/services/kubernetes-service/
- Yandex Managed Service for Kubernetes
   <a href="https://cloud.yandex.ru/services/managed-kubernetes">https://cloud.yandex.ru/services/managed-kubernetes</a>

# Вопросы?



Ставим "+", если вопросы есть




Ставим "–", если вопросов нет

## Компоненты Kubernetes

### Компоненты Kubernetes

- Кластер набор машин (узлы)
- Узлы запускают контейнеризированные приложения
- Под (модуль) группа из одного или нескольких тесно связанных контейнеров, которые всегда будут выполняться вместе на одном узле
- Поды размещаются в узлах
- Плоскость управления управляет рабочими узлами и подами в кластере
- Компоненты панели управления могут быть запущены на любом узле

### Компоненты Kubernetes



## Плоскость управления

- kube-apiserver клиентская часть панели управления
- etcd хранилище конфигурации кластера
- kube-scheduler распределяет приложения (назначает рабочий узел)
- kube-controller-manager функции кластерного уровня:
  - репликация компонентов
  - отслеживание рабочих узлов
  - обработка аварийных сбоев

## Компоненты узла

kubelet - агент, управляет контейнерами kube-proxy - сетевой прокси, балансирует нагрузку сетевого трафика

#### Среда выполнения контейнера:


- Docker
- rkt
- containerd
- CRI-O
- Kubernetes
- CRI (Container Runtime Interface)

#### Дополнения


Дополнения используют ресурсы Kubernetes для расширения функциональности кластера

- **Кластерный** DNS DNS-сервер наряду с другими DNS-серверами в вашем окружении, который обновляет DNS-записи для сервисов Kubernetes
- **Веб**-интерфейс (Dashboard) универсальный веб-интерфейс для кластеров Kubernetes
- Мониторинг ресурсов контейнера записывает общие метрики о контейнерах в виде временных рядов в центральной базе данных
- Логирование кластера отвечает за сохранение логов контейнера в централизованном хранилище логов


#### **Dashboard**



#### Запуск приложения



#### Запуск приложения



# Вопросы?



Ставим "+", если вопросы есть




Ставим "–", если вопросов нет


# Модули (Pods)

#### Знакомство с модулями

- Модуль это группа из одного или нескольких тесно связанных контейнеров
- Контейнеры внутри модуля используют один набор пространства имён
- Могут взаимодействовать по IPC
- Используют одно пространство ІР-адресов и портов




# Все контейнеры модуля работают на одном узле





Уел 1 Узел 2

#### Модули должны содержать тесно связанные контейнеры



# **Использование нескольких контейнеров** в модуле







#### Простое описание модуля

```
Описание соответствует версии v1 API Kubernetes
apiVersion: v1
kind: Pod
                         Вы описываете модуль
metadata:
  name: kubia-manual
                                Имя модуля
spec:
                                    Образ контейнера, из которого
  containers:
                                    создать контейнер
  - image: luksa/kubia
    name: kubia
                           Имя контейнера
    ports:
    - containerPort: 8080
                                      Порт, на котором приложение
       protocol: TCP
```

#### Организация модулей с помощью меток



#### Организация модулей с помощью меток



#### Указание меток при создании модуля

```
apiVersion: v1
kind: Pod
metadata:
  name: kubia-manual-v2
                                   Две метки прикрепляются
  labels:
    creation_method: manual
    env: prod
spec:
  containers:
  - image: luksa/kubia
  name: kubia
  ports:
  - containerPort: 8080
    protocol: TCP
```

# Вопросы?



Ставим "+", если вопросы есть




Ставим "–", если вопросов нет

# Контроллер репликации

#### Знакомство с контроллерами репликации

Контроллер репликации (ReplicationController) - это ресурс, который обеспечивает поддержание постоянной работы модулей




#### Три части контроллера репликации


**Контроллер репликации** состоит из трёх основных частей:

- *селектор меток* определяет какие модули находятся в области действия контроллера репликации
- количество реплик требуемое количество модулей, которые должны быть запущены
- *шаблон модуля* модуль, используемый при создании реплик

#### Три части контроллера репликации



#### Создание контроллера репликации



# Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

### Развёртывания (Deployment)

#### Знакомство с Развёртываниями

**Развёртывание** (Deployment) - это декларативное описание приложений



#### Создание Deployment

```
apiVersion: apps/v1beta1
                                                           Развертывание в группе
kind: Deployment
metadata:
  name: kubia
                                                   Вы изменили вид
                              Нет необходимости
                                                   с контроллера репликации
spec:
                              включать версию
  replicas: 3
                                                   на развертывание
                              в имя развертывания
  template:
    metadata:
      name: kubia
      labels:
        app: kubia
    spec:
      containers:
      - image: luksa/kubia:v1
      name: nodejs
```

# Вопросы?



Ставим "+", если вопросы есть




Ставим "–", если вопросов нет

# Службы (Service)


#### Знакомство со Службами

Служба (Service) - это ресурс, который формирует единую постоянную точку входа в группу модулей, представляющих

одну и ту же службу



#### Использование селекторов меток



#### Создание службы

```
apiVersion: v1
kind: Service
metadata:
  name: kubia
                                    Порт, в котором служба
spec:
                                    будет доступна
  ports:
                                        Порт контейнера, куда служба
  - port: 80
                                        будет перенаправлять
     targetPort: 8080
  selector:
                                      Все модули с меткой app=kubia 
будут частью службы
     app: kubia
```

# Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

### Model-as-a-Service

#### Flask приложение

```
from flask import Flask, jsonify, request
from sklearn import datasets
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
app = Flask(__name__)
def train_model():
    iris_df = datasets.load_iris()
    data = iris_df.data
    target = iris_df.target
    target_names = iris_df.target_names
    train_data, test_data, train_target, test_target = train_test_split(data, target, test_size=0.3)
    dt = DecisionTreeClassifier().fit(train_data, train_target)
    acc = accuracy_score(test_target, dt.predict(test_data))
    return dt, acc, target_names
model, accuracy, names = train_model()
```

#### Flask приложение (продолжение)

```
@app.route('/predict', methods=['POST'])
def predict():
    posted_data = request.get_ison()
    sepal_length = posted_data['sepal_length']
    sepal_width = posted_data['sepal_width']
    petal_length = posted_data['petal_length']
    petal_width = posted_data['petal_width']
    prediction = model.predict([[sepal_length, sepal_width, petal_length, petal_width]])[0]
    return jsonify({'class': names[prediction]})
@app.route('/model')
def get_model():
    return jsonify({'name': 'Decision Tree Classifier',
                    'accuracy': accuracy})
if name == ' main ':
    app.run(host='0.0.0.0')
```

#### **Dockerfile**

```
FROM photon
RUN tdnf install -y python3-pip libstdc++-devel
ENV FLASK_ENV=development
RUN mkdir -p /app
COPY app.py requirements.txt /app/
WORKDIR /app
RUN pip3 install --no-cache-dir -r requirements.txt
EXPOSE 5000
ENTRYPOINT ["python3"]
CMD ["app.py"]
```

# Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

# Deploy B Kubernetes

## minikube, "ручной" режим

- minikube start
- minikube addons configure registry-creds
- kubectl run iris --image=<name>/iris
- kubectl create deployment iris --image=<name>/iris
- kubectl expose deployment iris --type=LoadBalancer --port=5000
- minikube tunnel
- kubectl get service
- minikube stop

## minikube, "декларативный" режим

- kubectl apply -f deployment.yml
- kubectl apply -f service.yml
- minikube tunnel
- kubectl get service

## **Google Cloud Platform**

- docker tag iris gcr.io/bigdata-306618/iris
- docker push gcr. io/bigdata-306618/iris
- gcloud container clusters create cluster-1 --num-nodes=1
- kubectl create deployment iris image=gcr.io/bigdata-306618/iris
- kubectl expose deployment iris --type LoadBalancer --port=5000
- kubectl get pods
- kubectl get service iris
- kubectl delete service iris
- gcloud container clusters delete cluster-1

### **AWS**



## Вопросы?



Ставим "+", если вопросы есть



Ставим "–", если вопросов нет

# Литература

## Список литературы

- Kubernetes в действии https://dmkpress.com/catalog/computer/os/978-5-97060-657-5/
- Введение в технологии контейнеров и Kubernetes https://dmkpress.com/catalog/computer/os/978-5-97060-775-6/
- Осваиваем Kubernetes. Оркестрация контейнерных архитектур https://www.piter.com/collection/all/product/osvaivaem-kubernetes-orkestratsiva-kont evnernyh-arhitektur
- Kubernetes: Лучшие практики https://www.piter.com/collection/all/product/kubernetes-luchshie-praktiki
- Паттерны Kubernetes: Шаблоны разработки собственных облачных приложений https://www.piter.com/collection/all/product/patterny-kubernetes-shablony-razrab otki-sobstvennyh-oblachnyh-prilozheniy
- Kubernetes для DevOps: развертывание, запуск и масштабирование в облаке https://www.piter.com/product\_by\_id/169496565

### Ссылки

- 1. Kubernetes <a href="https://kubernetes.io/ru/">https://kubernetes.io/ru/</a>
- 2. Minikube <a href="https://kubernetes.io/ru/docs/tasks/tools/install-minikube/">https://kubernetes.io/ru/docs/tasks/tools/install-minikube/</a>
- 3. VMware Tanzu Community Edition <a href="https://tanzucommunityedition.io/">https://tanzucommunityedition.io/</a>
- 4. Red Hat OpenShift <a href="https://www.redhat.com/en/technologies/cloud-computing/openshift">https://www.redhat.com/en/technologies/cloud-computing/openshift</a>
- 5. VMware Tanzu <a href="https://tanzu.vmware.com/">https://tanzu.vmware.com/</a>
- 6. Octant <a href="https://octant.dev/">https://octant.dev/</a>
- KubeAcademy <a href="https://kube.academy/">https://kube.academy/</a>

# Рефлексия

## Рефлексия



С какими впечатлениями уходите с вебинара?



Как будете применять на практике то, что узнали на вебинаре?

Заполните, пожалуйста, опрос о занятии по ссылке в чате

#### Спасибо за внимание!

## Приходите на следующие вебинары



### Гайнуллин Дмитрий

Machine Learning Engineer в AIC

- Разработка моделей для распознавания речи
- Прогнозирование ключевых метрик
- Развертывание моделей в продакшене